

Clase 2.2 Aprendizaje de Máquina

Introducción a la Inteligencia Artificial

TUIA - 2025

Prof: Lic Alan Geary - email: alan.geary.b@gmail.com 


2.6 - ¿Cómo aprenden las máquinas?

Esta imagen es una metáfora visual del proceso de aprendizaje:

Ivan, el **modelo**, mediante el **uso** de un **cincel** en **forma repetitiva**, **algoritmo de aprendizaje**, extrae de los **datos**, la materia prima, el **patrón** (conocimiento aprendido) subyacente u oculto.



2.6 - ¿Cómo aprenden las máquinas?



1 Elegir la familia de **modelo**

2 Ajustar sus **hiper parámetros**.


3 **Aprender**: optimizar los parámetros internos sobre tus datos.

2.6 - ¿Cómo aprenden las máquinas?




NOMBRE	ALTURA	PESO
JUAN	150	68
MARÍA	155	55
PABLO	176	80
CECILIA	162	62
...	...	...


2.6 - ¿Cómo aprenden las máquinas?




2.6 - ¿Cómo aprenden las máquinas?



2.6 - ¿Cómo aprenden las máquinas?





2.6.1 - ¿Cómo aprenden las máquinas?



Para estimar los valores de parámetros (**m** y **h**) que minimizan el error
usamos el algoritmo de descenso de gradiente



2.6.1 - ¿Cómo aprenden las máquinas?




2.6.2 - Complejizar el modelo

Por otro lado, para obtener más información de los datos se puede **incrementar la complejidad del modelo**, aumentando su flexibilidad.

$$b = m_1 a + m_0$$


$$b = + m_2 a^2 + m_1 a + m_0$$

$$b = m_3 a^3 + m_2 a^2 + m_1 a + m_0$$




¡Notar que **h** se generalizó como **m_0** !!

2.6.2 - Complejizar el modelo



2.6.2 - Complejizar el modelo



2.6.2 - Complejizar el modelo


Si nuestro objetivo es que el modelo **aprenda** de los datos para predecir sobre datos nuevos. El problema es que contamos con los datos observados. (Nota: Esta idea es mucho más evidente para datos temporales porque ya pasaron)

2.6.2 - Complejizar el modelo

Si la **complejidad** del modelo toma **demasiada información** de los datos observados puede estar modelando más que la señal (relación subyacente). El modelo estará **sobreajustado**.

2.6.2 - Complejizar el modelo

Un modelo es útil (ajusta bien) si **generaliza** bien. Es decir, si tiene un buen desempeño para **predecir** datos nuevos.



2.6.2 - Complejizar el modelo

Una analogía para reforzar el concepto de sobreajuste

Estudia poco



Underfitting

Estudia mucho
entendiendo conceptos





Generaliza
Bien

Estudia de memoria





Overfitting


2.6.2 - Variables ocultas



2.6.2 - Variables ocultas




En el **Machine Learning** tradicional, la selección y extracción de características (features) es un proceso donde interviene un individuo a partir de los datos de entrada.



2.7 - tipos de aprendizaje

Tipos de machine learning



2.7.1 - aprendizaje supervisado

En el **aprendizaje supervisado**, los datos tienen la solución buscada (etiquetas).


Ejemplos de aplicación:

- Usar los píxeles de una imagen para detectar la presencia de un gato
- Usar datos del usuario para predecir si una película le va a gustar o no
- Usar las palabras que alguien dice para detectar si está feliz o triste
- Usar datos climáticos para predecir la probabilidad de lluvia


2.7.1 - aprendizaje supervisado

EDAD	GÉNERO	¿FUMA?	¿VACUNADO?	¿ENFERMO?
18	M	0	1	0
41	F	0	0	0
33	F	1	0	1
24	M	0	1	0
65	M	1	0	1
19	F	0	1	0


Regresión




Clasificación



2.7.1 - aprendizaje supervisado



Clasificación



Regresión

2.7.1 - aprendizaje supervisado

Regresión



¿Qué temperatura
hará mañana?

84°



Fahrenheit

Clasificación



¿Mañana será un día
frío o de calor?

COLD

HOT



Fahrenheit

2.7.1 - aprendizaje supervisado

Regresión Lineal

Da como resultado un valor continuo a partir de una combinación lineal de atributos de entrada.


Regresión Polinómica

Es un caso especial de regresión lineal donde ajustamos una ecuación polinómica en los datos con una relación curvilínea entre la variable objetivo y las variables independientes.


Árboles de regresión

Árboles de decisión, donde la variable de destino puede tomar valores continuos.



Linear Regression




Polynomial Regression



2.7.1 - aprendizaje supervisado




2.7.1 - aprendizaje supervisado



2.7.1 - aprendizaje supervisado

[23, 74, 295, 388]
[x_min, y_min, width, height]



[377, 294, 252, 161]
[x_min, y_min, width, height]

[333, 421, 49, 49]
[x_min, y_min, width, height]

2.7.1 - aprendizaje supervisado

Regresión Logística

A pesar de su nombre es un método para problemas de clasificación, en los que se obtienen un valor binario entre 0 y 1.

Árbol de decisión


Cada nodo interno denota una prueba en un atributo, cada rama representa el resultado de una prueba, y cada hoja nodo tiene una etiqueta. El nodo superior en un árbol es el nodo raíz (algoritmo también aplicado en regresión).

Bosque aleatorio (Random Forest)

Es un método que combina una cantidad grande de árboles de decisión independientes probados sobre conjuntos de datos aleatorios con igual distribución(algoritmo también aplicado en regresión).


Support Vector Machines (SVMs)

El objetivo es encontrar un hiperplano en un espacio N-dimensional que clasifica claramente los puntos de datos (algoritmo también aplicado en regresión).




2.7.1 - aprendizaje supervisado


Al papá de Sofía le encanta cocinar galletitas. Sofía descubrió que le gustan muchas de las galletitas que hace su papá pero hay otras que prefiere darle a su hermano. Para cada galletita, toma nota del tamaño y de la cantidad de chips de chocolate que tiene y registra si le gustó o no.



aprendizaje supervisado




2.7.1 - aprendizaje supervisado



A Sofía no le gustan las galletitas que son grandes y tienen pocos chips de chocolate



2.7.1 - aprendizaje supervisado





A Sofía no le gustan las galletitas que son grandes y tienen pocos chips de chocolate

¿Podemos establecer algorítmicamente algunas reglas? ¿Cuál de estos criterios separa *mejor* los datos?



2.7.1 - aprendizaje supervisado



Esto es un árbol de decisión




2.7.1 - aprendizaje supervisado

Podemos construir un **modelo** que *aprenda* una serie de reglas (que pueden ser flexibles) a partir de datos para poder explicar un determinado comportamiento


Esperamos que el comportamiento se mantenga (que los datos sean representativos: que las galletitas sigan el patrón observado) para poder hacer predicciones en datos nuevos



2.7.1 - aprendizaje supervisado



2.7.1 - aprendizaje supervisado



		predicción	
		RICAS	FEAS
verdad	RICAS	18 ✓	4
	FEAS	0	8 ✓

Hay que **evaluar el desempeño** de los **modelos**

2.7.1 - aprendizaje supervisado

		predicción	
		<i>RICAS</i>	<i>FEAS</i>
verdad	<i>RICAS</i>	18	4
	<i>FEAS</i>	0	8

✓ **Accuracy (Precisión global)**: qué porcentaje se predijo bien.

👉 $(VP + VN) / \text{Total}$

Sirve para: saber cuántas veces acertó el modelo en general.

Ejemplo:

En un sistema de reconocimiento facial para abrir una puerta, si el modelo acierta el 98% de las veces, entonces la **accuracy** es buena... **salvo** que los errores sean graves (por ejemplo, dejar pasar a un desconocido).

$$\text{Accuracy} = \frac{\text{Verde} + \text{Azul}}{\text{Verde} + \text{Azul} + \text{Amarillo} + \text{Rojo}} = \frac{18+8}{18+8+0+4} = \frac{26}{30} = 0,87 \times 100 = 87\%$$



2.7.1 - aprendizaje supervisado

		predicción	
		<i>RICAS</i>	<i>FEAS</i>
verdad	<i>RICAS</i>	18	4
	<i>FEAS</i>	0	8

 **Precisión:** de los que predije como positivos, ¿cuántos lo eran?
👉 $VP / (VP + FP)$

Sirve para: evitar falsos positivos. Ideal si los errores al “aceptar” son costosos.

Ejemplo:

En detección de spam, una alta **precisión** significa que casi todos los correos que marcó como spam **realmente lo son** (evitó que correos buenos vayan a la carpeta equivocada).

$$\begin{array}{c} \text{Precisión} \\ \text{Clase 1} \end{array} = \frac{\text{VP}}{\text{VP} + \text{FP}} = \frac{18}{18+0} = 1 \times 100 = 100\%$$



2.7.1 - aprendizaje supervisado

predicción

verdad

	<i>RICAS</i>	<i>FEAS</i>
<i>RICAS</i>	18	4
<i>FEAS</i>	0	8

 **Recall (Sensibilidad):** de los positivos reales, ¿cuántos detecté?
👉 $VP / (VP + FN)$

Sirve para: no dejar pasar casos verdaderos. Ideal si lo importante es **no perderse ninguno**.

Ejemplo:

En un test de cáncer, queremos un alto **recall**: detectar todos los casos posibles, aunque se nos “escape alguno sano” como positivo.

$$\begin{array}{c} \text{Recall} \\ \text{Clase 1} \end{array} \quad \frac{\text{orange square}}{\text{orange square} + \text{green square}} \quad \equiv \quad \frac{18}{18+4} \quad \equiv \quad 0,82 \times 100 \quad \equiv \quad 82\%$$



2.7.1 - aprendizaje supervisado

predicción

verdad

	<i>RICAS</i>	<i>FEAS</i>
<i>RICAS</i>	18	4
<i>FEAS</i>	0	8

 **Especificidad:** de los que predije como negativos, ¿cuántos lo eran?

👉 $VN / (VN + FP)$

Sirve para: Expresa cuán bien puede el modelo detectar esa clase.

En términos de salud: Verdaderos Negativos / Total Sanos

En el área de la salud se dice que la especificidad es la capacidad de poder identificar los casos de pacientes sanos entre todos los sanos.

Precisión Clase 2

$$\frac{\text{Verdaderos Negativos}}{\text{Verdaderos Negativos} + \text{Falsos Positivos}} = \frac{8}{8+4} = 0,66 \times 100 = 66\%$$



2.7.1 - aprendizaje supervisado

		predicción	
		<i>RICAS</i>	<i>FEAS</i>
verdad	<i>RICAS</i>	18	4
	<i>FEAS</i>	0	8

 **F1 Score:** equilibrio entre precisión y recall.
 $2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$

Sirve para: equilibrar precisión y recall cuando ambas son importantes.

Ejemplo:

En un sistema de moderación de comentarios tóxicos, queremos tanto **no dejar pasar** mensajes ofensivos (**recall**) como **no censurar** mensajes inocentes (**precisión**). El **F1** ayuda a evaluar ese balance.

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = 2 \times \frac{0,66}{1,66} \approx 2 \times 0,3976 \approx 0,795$$



2.7.1 - aprendizaje supervisado




Figura 1. Diagrama de flujo del aprendizaje supervisado



2.7.2 - aprendizaje no supervisado

En el aprendizaje **no supervisado**, los datos no tienen etiquetas.


El sistema “aprende” sin una respuesta correcta. Se parte de un conjunto de datos que no es bien entendido o conocido.

2.7.2 - aprendizaje no supervisado


EDAD	GÉNERO	ESTADO CIVIL	OCUPACIÓN	CÓDIGO DE PRODUCTO
18	M	Soltero	Estudiante	S212
41	F	Casado	Enfermería	M211
33	F	Soltero	Ingeniería	S600
24	M	Soltero	Contabilidad	S703
65	M	Soltero	Jubilado	M107
31	F	Casado	Administrativo	S212



2.7.2 - aprendizaje no supervisado



2.7.2 - aprendizaje no supervisado



2.7.2 - aprendizaje no supervisado

Tenemos un grupo de personas a las que le hemos medido su altura. Y pretendemos separar en dos grupos que representen a bajos y altos. Esto es lo que se parecen en la altura que tienen y los que no.



2.7.2 - aprendizaje no supervisado

Nombre	Altura			Nombre	Altura
Luis	1.78			Sergio	1.77
Julia	1.56			Eleonor	1.57
Maria	1.63			Carina	1.65
Pedro	1.85			Matias	1.64
Alvaro	1.71			Nicolás	1.59
Gonzalo	1.9			Santiago	1.73
Teresa	1.7			Beatriz	1.7
Paula	1.55			Miriam	1.62
Sandra	1.8			Jorge	1.85
Mabel	1.67			Yael	1.69
Oscar	1.76			Pablo	1.77
media	1.719090909			media	1.689090909

2.7.2 - aprendizaje no supervisado

Dos tipos de **relaciones** definen a los grupos y a los elementos de los grupos.



Una **intra** grupo:
Dentro del mismo grupo tienden a ser **parecidos**

Una **entre** grupos:
Que tratan de ser **diferentes**



2.7.2 - aprendizaje no supervisado

The diagram illustrates unsupervised learning by showing two clusters of data points and their centroids. Two large red curved arrows point from the centroids to the data points belonging to their respective clusters.

Nombre	Altura		Nombre	Altura
Luis	1.78		Sergio	1.77
Julia	1.56		Eleonor	1.57
Maria	1.63		Carina	1.65
Pedro	1.85		Matias	1.64
Alvaro	1.71		Nicolás	1.59
Gonzalo	1.9		Santiago	1.73
Teresa	1.7		Beatriz	1.7
Paula	1.55		Miriam	1.62
Sandra	1.8		Jorge	1.85
Mabel	1.67		Yael	1.69
Oscar	1.76		Pablo	1.77
media	1.719090909		media	1.689090909
Nombre	Altura		Nombre	Altura
Luis	1.78		Julia	1.56

2.7.2 - aprendizaje no supervisado




Figura 2. Diagrama de flujo del aprendizaje no supervisado

2.7.3 - aprendizaje por refuerzo

En el **aprendizaje por refuerzo**, no hay etiquetas; el agente aprende interactuando con el entorno y recibe recompensas por sus acciones.

Ejemplos de aplicación:

Aprender a jugar al ajedrez ganando puntos por partidas ganadas.

Aprender a manejar un robot que recibe premio si llega al destino.

Aprender a jugar en un videojuego probando movimientos y corrigiendo errores.

2.7.3 - aprendizaje por refuerzo



X	O	O
O	X	X
		X

gle

浙江省体育局



00:31



ALPHAGO

02:02






2.7.3 - aprendizaje por refuerzo

MODELO DE APRENDIZAJE POR REFUERZO

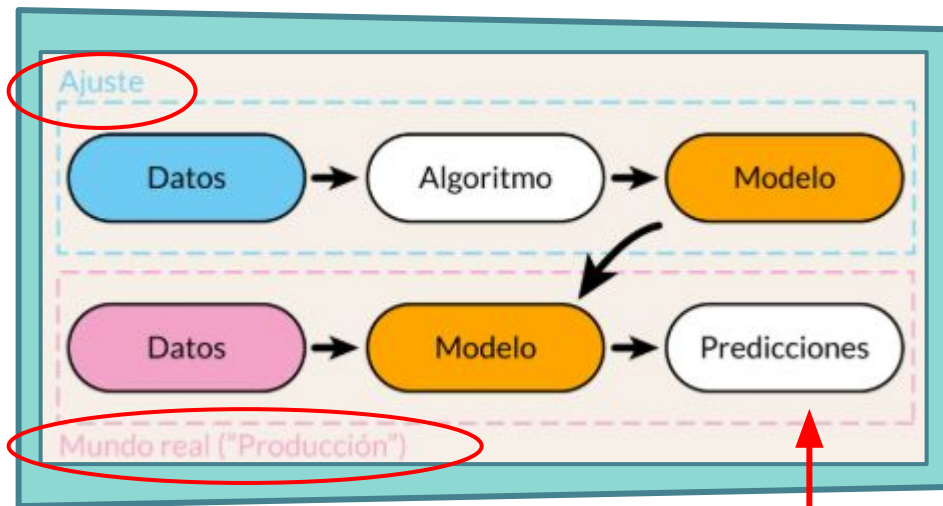


Figura 3. Diagrama de flujo aprendizaje por refuerzo

2.7.3 - aprendizaje por refuerzo



2.7.4 - Predicciones




Objetivo: usar nuestro modelo para realizar predicciones sobre datos nuevos (en el futuro)

El modelo sirve ("ajusta bien") a los datos que le damos... si conociéramos lo que va a venir en el futuro, seríamos tan felices... pero no lo sabemos

¿Cómo hacemos?
¿Confiamos?



2.7.4 - Predicciones



No... en general no alcanza con “confiar”.

Separamos el conjunto original de datos en datos de entrenamiento (train) y datos de evaluación (test). Perdemos algunos datos para ajuste del modelo.



NOTAR QUE SUPONEMOS QUE NUESTROS DATOS SON REPRESENTATIVOS

2.7.4 - Predicciones

Los datos traen señal y ruido

En el ajuste del modelo, puede ocurrir que el modelo se entusiasme mucho con los **datos que le damos** y encuentre patrones donde no los hay

Hay un ajuste perfecto en **entrenamiento** pero el desempeño en el **mundo real** es malo.

Overfitting es construir un modelo **demasiado complejo**. La tensión fundamental en machine learning es entre ajustar los datos correctamente y hacerlo de la manera más simple posible.

2.7.4 - Predicciones

Los modelos muy flexibles tienen alta **varianza**.


Varianza: ¿cuánto cambia el modelo si lo ajustamos a otros datos de entrenamiento?

Los modelos muy flexibles tienen bajo **sesgo**.



Sesgo: ¿cuánto perdemos por aproximar la realidad con nuestro modelo?

Buscamos un modelo con **baja varianza y bajo sesgo**... el problema es que cuando uno aumenta el otro disminuye (y viceversa).



Imaginemos repetir la construcción del modelo muchas veces con nuevos datos...





2.7.4 - Predicciones



2.6.2 - Complejizar el modelo



2.6.2 - Complejizar el modelo






2.6.2 - Complejizar el modelo

Hacer **predicciones** involucra lo que sabemos y lo que no sabemos: incorporar lo que sabemos para tratar de formular una teoría (un modelo) sobre lo que aún no observamos...

Un **modelo** más complejo siempre va a poder ajustar mejor a los datos de **entrenamiento** (es más sensible a los datos), pero eso **no implica** una mejor **predicción**.

Flexibilidad significa mayor capacidad para ajustar los patrones en los datos, incluso cuando estos patrones sean casualidad

2.9 - Ejemplos de uso



- Ejemplos de uso - Recomendaciones

El motor de recomendaciones de **Netflix** usa un modelo de aprendizaje no supervisado. Y define tu similitud con otros usuarios y te recomienda en relación a gustos de consumidores similares a vos.



- Ejemplos de uso - Recomendaciones

El problema de recomendación de spotify era la necesidad de generar resultados. Su algoritmo de recomendación se basa en una sofisticación del algoritmo **K-means** (Annoy) un tipo de aprendizaje no supervisado.



- Ejemplos de uso - Del pan a las células

Historia de **Hisashi Kambe** y cómo la necesidad de agilizar los pagos en panaderías los llevó a diseñar **BakeryScan** con métodos de visión clásica, antes de que el aprendizaje profundo fuese viable.



[The New Yorker](#)

- Ejemplos de uso -

Del pan a las células

Panaderías japonesas ofrecen **gran variedad de productos** (100+ tipos) y los venden sin empaques y sin código de barras.

Problemas: Los cajeros debían memorizar todos los productos y precios
→ **filas largas, errores y baja higiene.**

Desafío: ¿Cómo automatizar el proceso de cobro?



- Ejemplos de uso - Del pan a las células

BakeryScan se lanzó en 2013, alcanzando gran precisión y uso en cientos de panaderías.


Luego su tecnología (**AI-Scan**) se aplicó a nuevas áreas: diagnóstico de células cancerosas, industria textil, identificación de píldoras, inspección industrial, etc



- Ejemplos de uso - Del pan a las células

La nueva versión del BakeryScan AI se llama **Cyto-AISCAN** y puede ampliar las células cancerosas y distinguirlas entre innumerables en un portaobjetos completo.

Esto permite a los médicos distinguir las células cancerosas de las que aún no lo son.



- Ejemplos de uso -

Utilizan **algoritmos de agrupamiento** para segmentar su enorme base de clientes.

Al analizar los historiales de compras y patrones de navegación, pueden enviar recomendaciones y ofertas personalizadas a diferentes segmentos de clientes.

Este enfoque ha sido un factor clave en el éxito de **Amazon**, ayudándole a dominar el espacio del comercio electrónico al ofrecer una experiencia de compra más personalizada.



- Ejemplos de uso -

- Anomalías en ciberseguridad-



El aprendizaje no supervisado es como tener un **agente de tráfico** que detecta estos **patrones inusuales** en el tráfico de la red. Al analizar los datos, puede identificar posibles amenazas de seguridad que no se ajustan al patrón habitual, como un aumento repentino en la transferencia de datos o intentos de inicio de sesión inusuales.




2.8 - Desafíos



No es magia...

sesgo de selección

- Pocos datos de entrenamiento
- Datos de entrenamiento **no representativos**
- Datos de mala calidad (*garbage in, garbage out*).
- Features irrelevantes



Es decir, el "grupo observado" está **sesgado**: solo incluye a quienes ya conocen el término, y excluye a los que no lo conocen, que no levantarán la mano y no serán contados.


2.8 - Desafíos




No es magia...

- Pocos datos de entrenamiento
- Datos de entrenamiento **no representativos**
- Datos de mala calidad (*garbage in, garbage out*).
- Features irrelevantes


sesgo de selección



sesgo de supervivencia



2.8 - Desafíos



Automated Inference on Criminality using Face Images

Xiaolin Wu
Shanghai Jiao Tong University
xwu510@gmail.com

Xi Zhang
Shanghai Jiao Tong University
zhangxi.19930818@sjtu.edu.cn



(a) Three samples in criminal ID photo set S_c .



(b) Three samples in non-criminal ID photo set S_n .

Fin unidad 2