


UNIDAD 2. Material de estudio

2.1 Inteligencia Artificial, ciencia de datos y aprendizaje de máquina.

En nuestra exploración de la inteligencia artificial, nos encontramos con un campo esencial: el aprendizaje automático, o "machine learning". Imaginen por un momento que tienen delante un mecanismo complejo, similar a un reloj. Cada engranaje en este reloj tiene la capacidad de ajustarse para mejorar su funcionamiento general sin intervención externa. Así funciona el aprendizaje automático: es la ciencia de dotar a las máquinas de la capacidad de ajustar sus engranajes internos—sus algoritmos—para aprender de las experiencias pasadas, en esencia, para que puedan mejorar su desempeño en tareas específicas.

El aprendizaje automático es una rama dentro del vasto árbol de la inteligencia artificial.




UNIDAD 2. Material de estudio

Si consideramos a la inteligencia artificial como el objetivo de crear sistemas que puedan razonar, aprender y actuar de manera independiente, el aprendizaje automático sería una de las principales ramas que permite a estos sistemas aprender de los datos y experiencias pasadas analizando. Es como enseñar a un niño a través de ejemplos en lugar de reglas estrictas y fijas. El aprendizaje automático es una rama fundamental de la inteligencia artificial, cuyo objetivo es crear sistemas capaces de razonar, aprender y actuar de forma autónoma. A través del aprendizaje automático, estos sistemas adquieren conocimiento a partir de datos y experiencias previas, de manera similar a como un niño aprende a través de ejemplos, en lugar de seguir reglas rígidas y preestablecidas.

A menudo, el aprendizaje automático y la ciencia de datos se entrelazan en conversaciones, y aunque son cercanos, tienen diferencias fundamentales. Podríamos decir que la **ciencia de datos** es como la arqueología: implica excavar (recolectar datos), limpiar (preparar datos) y examinar cuidadosamente lo encontrado (analizar) para hacer descubrimientos (*insights*).

Por otro lado, el aprendizaje automático toma estos descubrimientos y los utiliza para construir modelos predictivos o descriptivos. Mientras que la ciencia de datos puede proporcionar la partitura, el aprendizaje automático toca la música.



UNIDAD 2. Material de estudio

2.2 La materia prima: Los datos

Para explicar en profundidad esta rama vamos a definir el recurso sustancial con que las máquinas aprenden, los datos¹. Ejemplos de set de datos tabular:

En la siguiente gráfica cada fila es una **observación o individuo**, engloba las “*features*” o “características” propias de esta observación. El ejemplo de la primera fila de la tabla superior nos informa sobre una persona de nombre María, su edad, título o grado de estudio y correo electrónico personal.

Diagrama de una tabla con anotaciones de Nombres Filas, Columnas, Nombres Columnas y Filas.

	Nombre	Edad	Grado	Correo
1	María	18	Economía	maria@gmail.com
2	Luis	22	Medicina	luis@yahoo.es
3	Carmen	20	Arquitectura	carmen@gmail.com
4	Antonio	21	Economía	antonio@gmail.com

Nombre	Edad	Profesión	Correo	Fumador	Peso (kg)	Altura (m)	Presión Arterial Sistólica
Juan Pérez	28	Ingeniero	juan.perez@mail.com	No	78	1.80	120
María Gómez	22	Médica	maria.gomez@mail.com	Sí	65	1.68	115
Carlos Ruiz	35	Profesor	carlos.ruiz@mail.com	No	85	1.82	130
Ana López	30	Arquitecta	ana.lopez@mail.com	No	70	1.70	125
Luis Torres	40	Abogado	luis.torres@mail.com	Sí	90	1.75	135

¹ Existen muchos tipos de datos como formatos y estructuras para almacenar o compartirlos. Aquí, se presenta un esquema sencillo de una estructura tabular con la que trabajaremos en los ejemplos.

UNIDAD 2. Material de estudio

Luego, en un ejemplo más completo, de la última tabla se detalla a continuación el tipo de variable que representa cada columna del dataset:

Correo: representa la dirección de correo electrónico asociada a cada observación y es de tipo cualitativo nominal. Esto significa que sus valores son cadenas de texto sin un orden inherente. En la mayoría de los casos, cada dirección de correo es única, lo que genera un problema de alta cardinalidad; es decir, existen muchos valores distintos que, en general, no se repiten. Por ello, esta variable rara vez se utiliza directamente como una característica predictiva en modelos de machine learning, ya que no aporta información cuantitativa ni patrones fácilmente generalizables.²

Edad: Es una variable cuantitativa discreta (aunque en algunos contextos podría tratarse como continua si se tuviera una medición más precisa) que representa la cantidad de años.

Profesión: Es una variable cualitativa nominal, ya que sus categorías (Ingeniero, Médica, Profesor, etc.) no poseen un orden inherente.

Fumador: Es una variable cualitativa dicotómica (binaria) nominal, donde se registran dos posibles categorías: Sí o No.

Peso (kg): Es una variable cuantitativa continua, ya que puede tomar cualquier valor dentro de un rango (por ejemplo, 78.5 kg).

Altura (m): Es una variable cuantitativa continua, pues permite valores en un rango continuo (como 1.80 m).

² Sin embargo, se pueden extraer componentes o atributos derivados, como el dominio (por ejemplo, "gmail.com", "yahoo.com", etc.), que podrían utilizarse para segmentar o agrupar las observaciones. Además, el manejo de esta variable debe considerar aspectos de privacidad y confidencialidad, puesto que contiene datos personales sensibles.

UNIDAD 2. Material de estudio

Presión Arterial Sistólica: Es una variable cuantitativa numérica. Dependiendo de la precisión de la medición, se podría considerar discreta (por ser un entero, por ejemplo, 120 mmHg) o continua para efectos de análisis.

Pero, dado que las computadoras entienden el mundo de forma binaria, su lenguaje es numérico. Por lo tanto, en realidad el modelo consumirá los datos de la manera siguiente:

ID	Edad	Profesión (Codificada)	Fumador (Codificado)	Peso (kg)	Altura (m)	Presión Arterial Sistólica
1	28	0 (Ingeniero)	0 (No)	78	1.80	120
2	22	1 (Médica)	1 (Sí)	65	1.68	115
3	35	2 (Profesor)	0 (No)	85	1.82	130
4	30	3 (Arquitecta)	0 (No)	70	1.70	125
5	40	4 (Abogado)	1 (Sí)	90	1.75	135

Este es un ejemplo de un set de datos listo para ser consumido por un modelo de aprendizaje automático. En este caso, se decidió eliminar la variable “correo” por no proporcionar información relevante y se ven codificadas en números las variables “Profesión” y “Fumador”

2.3 Lo empírico, lo ideal y el modelo

Llegados a este punto en general es recomendable tener en claro estos dos términos. Entonces:


Empírico se refiere a lo que se basa en la experiencia directa o en la observación de los hechos, en lugar de en teorías o principios abstractos. Por ejemplo los datos de las tablas del apartado anterior se obtienen de la observación, la exploración, la pregunta y las respuesta de personas tomadas del mundo a partir de diferentes estrategias o instrumentos. O como decimos en ciencias “resultados del trabajo de campo”.

NOMBRE	ALTURA
JUAN	150

UNIDAD 2. Material de estudio

Imaginemos que tengo un curso con X cantidad de alumnos/as. Elijo uno y le pregunto el nombre (JUAN) luego tengo una cinta métrica y le pido tomar la altura.


Entonces, cómo sé que Altura es una variable cuantitativa continua imagino que si trazo un eje vertical podría colocar un punto sobre la misma que representa la altura de Juan.



Imaginemos que también quiero y puedo pesar a JUAN. Ahora, dispongo de otra variable que lo caracteriza, el PESO.


Entonces, tengo una nueva "dimensión" que puedo representar en otro eje, se me ocurre que puedo mapear a JUAN en forma más informativa ayudándome de esa manera.

UNIDAD 2. Material de estudio



Luego, las “coordenadas” 68 kilogramos y 150 cms describen en 2 “dimensiones” al individuo JUAN.

Siguiendo con esta lógica podría mapear a toda la comisión. Así, nuestro resultado de recolección de datos podría estar representado en dos dimensiones de la siguiente forma:




UNIDAD 2. Material de estudio

Conformando una “nube de puntos”, la cual representa el conjunto de las “observaciones” que pude relevar del alumnado correspondiente a esa división que estaban presentes en ese día. Decimos que esta información proviene de un enfoque **empírico** del conocimiento.

Ideal: se refiere a algo que existe únicamente en el ámbito del pensamiento, las ideas o la imaginación, pero que no necesariamente tiene una correspondencia directa con la realidad física o con la experiencia empírica. Lo ideal suele estar relacionado con modelos, conceptos abstractos o representaciones mentales que se consideran perfectas o deseables, pero que pueden no ser alcanzables en la práctica.


Para comparar esquemas en el mismo marco utilicemos una representación que incluye ambos ejes cartesianos. Por ejemplo, en la representación de funciones continuas univariadas que vemos en análisis matemático, detrás del concepto de función tenemos una forma de representar dos valores por medio de una ley o relación. Esta construcción teórica no incluye elementos que no están contenidos. El comportamiento allí representado se considera ideal. En el sentido de que la abstracción necesaria para lograrlo no permite complejizar más que lo que determina la relación. Solo se pretende representar la relación “pura”.



Así, en las siguientes funciones podemos decir que cualquier valor que tome X podrá ser representado sobre una curva continua de forma exhaustiva, es decir sin dejar afuera ninguna información adicional al tener en cuenta la ley y los valores de Y. Para decirlo de la otra forma, toda la representación se contiene a sí misma.

UNIDAD 2. Material de estudio


Entonces definimos así representaciones de relaciones **ideales** entre variables. Por ejemplo:



El concepto de **Modelo** (línea celeste) es la implementación de una estructura teórica *ideal* para abstraer la **relación subyacente** (que existe oculta o que hay por detrás) entre partes o **características observadas** (ej: mensuras de altura y peso) de **elementos de la realidad** (ej: personas de una comisión).

UNIDAD 2. Material de estudio

Y = altura




Lo que hacemos aquí es *suponer* que “idealmente” (si pudiéramos aislar el peso y la altura de todo lo demás que compone la realidad) una la relación entre el peso y altura que presenta una forma **teórica lineal** (las variables están **CORRELACIONADAS** linealmente). O sea, se modeliza esta relación por medio de una recta. La recta es nuestro *modelo* del comportamiento entre esas características propias de un individuo.

2.4 Correlación no es causalidad

Siguiendo con el ejemplo, una vez recolectadas las observaciones o muestra y mapeada en un plano cartesiano podremos observar algún patrón subyacente en la forma que toma la dispersión de la nube de puntos obtenida entre valores de 2 variables. Como vimos en gráficas anteriores.

A pesar de que en otras materias podremos definir la fuerza o intensidad de esa relación mediante metodologías más precisas, por ahora, apoyarse en la exploración visual es suficiente para desarrollar la afirmación que enuncia este apartado: “La correlación no es causalidad”

UNIDAD 2. Material de estudio



En el ejemplo anterior vemos cuatro posibles diagrama de dispersión. En primer lugar (izq. arriba) encontramos un ejemplo parecido al que trabajamos anteriormente. Donde la *relación subyacente* entre las variables parecen evidenciar una relación lineal directa. Esto quiere decir que al incrementarse una se incrementará la otra. Por eso, podemos pensar en modelizar esta relación por medio de una línea recta con una pendiente hacia arriba y que su inclinación depende de la magnitud de cambio relativo entre las medida de las observaciones entre las variables. Así, esta nube de puntos podría pensar que “oculta” una relación proporcional directa entre ambas variables.

Si continuamos con la imagen de la derecha, notamos que mientras una variable aumenta la otra disminuye (relación lineal indirecta). También, observamos que se forma una nube de puntos más dispersa. Si bien, existe un patrón que puede evidenciar un componente de linealidad en la relación, la cantidad de información restante (que no se ajusta a esa idea), y que no contempla ese supuesto parece importante.

En la tercera imagen (izq. abajo), se observa una nube de puntos sin un patrón definido. Se hace difícil suponer una ley que explique una relación “ideal” subyacente entre las variables.


UNIDAD 2. Material de estudio

Por último, en el caso de la derecha, podemos intuir una relación no lineal pero podría obedecer a un patrón subyacente de tipo cuadrático, o mejor dicho, que una variable se explique por el cuadrado de la otra. Entonces, ese podría ser el componente principal de esta relación, el modelo subyacente que podemos proponer para explicarla.

Ahora bien, tengamos en cuenta que estos datos con los que se realizaron estas gráficas tienen serias restricciones para informarnos de la relación entre las variables en cuestión. ¿Por qué? Por ejemplo, es evidente que corresponde a un fragmento de la realidad, no a la realidad en su totalidad. Es decir, que se encuentra delimitada al *grupo* con el que se trabajó, el *momento*, el *lugar* y probablemente sobre una realidad que puede ser mucho más amplia.

Por un lado, no tendríamos información más allá de los valores extremos que observamos en cada variable (min-max). Esto es así porque hemos observado indicios de una parte del fenómeno (la relación entre las variables), la parte de la que pudimos recolectar datos. Por otro lado, el movimiento conjunto de determinados valores puede ser únicamente el resultado de la casualidad para ese momento y que en realidad no exista ningún patrón subyacente ni fenómeno explicable entre esos datos recolectados. Veamos algunos ejemplos:

El siguiente es un patrón de correlación entre cantidad de ahogados en pileta y los films en los que participó Nicolas Cage entre los años 1999 y 2009.



Si no tuviésemos en cuenta lo que los datos representan, podríamos intuir que el movimiento de las variables observadas en estos dos fenómenos podrían ocultar un patrón que explique su relación. Sin embargo, al conocer su procedencia, creemos mucho más probable que se deba a una casualidad. Por cosas como esta, al afrontar un problema de

UNIDAD 2. Material de estudio

modelización, siempre será necesario que tengamos en cuenta el conocimiento sobre el fenómeno que estamos tratando de explicar. Apoyar las conclusiones en la consulta de un experto así como en la documentación existente sobre el hecho estudiado.

El enfoque del análisis de datos trata de eliminar el sesgo *subjetivo*³ de la explicación del fenómeno, buscando aplicar una metodología de análisis que no se encuentre influida por opiniones. El problema es que la *correlación* puede no tener ningún fundamento para la explicación y deberse a la casualidad. Lo que puede llevar a afirmar cosas absurdas para explicar un fenómeno, como en el ejemplo anterior .

IMPORTANTE: La **correlación** sólo significa que **dos cosas varían juntas**. Entonces no podemos adjudicar causalidad en ninguna dirección. En nuestro ejemplo: Ni Cage → Ahogados, ni vice versa.

2.5 ¿Cómo aprenden las máquinas?.

Como subcampo de la inteligencia artificial, el aprendizaje automático se define por la construcción y uso de **algoritmos** para entrenar *modelos* con una característica particular: son capaces de **aprender de los datos**. Y una vez entrenados, serán capaces **realizar predicciones** sin necesidad de una programación específica para cada situación.

Es importante destacar que **la salida o variable respuesta (Y) puede adoptar diversas formas**. Muchas técnicas asumen que la salida es una variable categórica, es decir, que pertenece a un conjunto finito de categorías (como "masculino" o "femenino"), o que es un número real, como puede ser el *nivel de ingresos*. Cuando la salida es categórica, se trata de un problema de **clasificación** y cuando es continua (un número real) se aborda como un problema de **regresión**.⁴

El concepto de **algoritmo** ocupa una posición central. Los algoritmos son procedimientos o fórmulas para resolver problemas, que en este contexto se especializan en analizar y


³ Que depende de la percepción, sentimientos, opiniones o experiencias personales de un individuo.

⁴ Existe también una variante llamada regresión ordinal, en la que las categorías tienen un orden natural, como en el caso de calificaciones que van de A a F.

UNIDAD 2. Material de estudio

aprender de los datos. Funcionan como el cerebro detrás del proceso, diseñados para identificar patrones y regularidades en los datos que reciben.

El **modelo**, por otro lado, es el resultado concreto de estos algoritmos. Se puede entender como una estructura o marco matemático construido y perfeccionado por el algoritmo a medida que procesa y aprende de los datos. Este modelo encapsula el conocimiento extraído durante el entrenamiento y se utiliza para hacer **inferencias o predicciones** sobre **nuevos conjuntos de datos**. Así, mientras el algoritmo es el *proceso* de aprendizaje, el modelo es, en esencia, la *cristalización* de ese aprendizaje.




Como podemos observar en la figura anterior, el conjunto de las observaciones etiquetadas (1) que conforman nuestro conjunto de datos recolectados deben ser *fraccionados* antes de entrenar. (2) Este requerimiento es indispensable para evaluar el proceso de entrenamiento una vez terminado. Esa evaluación debe hacerse sobre observaciones que no pertenecen al conjunto con el que se ha entrenado el modelo (training set) y que además, deben poseer la **etiqueta**. Esto quiere decir que son datos que pertenecen a las observaciones y de los que sabemos la respuesta. ¿Por qué?... Porque para poder evaluar algo necesitamos poder medir contra otra cosa. Si no sabemos las respuestas no podríamos contrastar si las predicciones que el modelo devuelve al introducir los datos del grupo de testeo (Test set) son certeras o no.

En la siguiente imagen la parte superior es una simplificación del proceso de **ajuste** de la figura anterior. La parte inferior, **producción**, representa la utilización del modelo ya entrenado con datos nuevos para obtener una predicción (correspondiente a uno de los posibles valores del rango de posibilidades para la variable “etiqueta” con la que se entrenó)⁵

⁵ En este caso la presión arterial sistólica

UNIDAD 2. Material de estudio




Entender los datos como la *materia prima* que consumen estos **algoritmos** es una metáfora productiva. Aquí, los **datos limpios** que se le otorgan al **algoritmo**, representan el mineral en bruto que se extrae a partir de procesos de “minado”. Conformando un dataset con los datos que serán el input del algoritmo. Es aquí donde los algoritmos aplican técnicas *estadísticas* y de análisis para discernir estructuras o patrones que pueden no ser inmediatamente evidentes. Este proceso no solo implica absorber datos, sino también *transformarlos* en una forma que los **modelos** puedan utilizar efectivamente para hacer predicciones precisas y útiles.

Finalmente, una vez entrenado el modelo, este ya no cambia, se han **estimado** los **parámetros**. La **predicción** será el resultado de ingresar nuevos datos al modelo. Utilizando el conocimiento adquirido durante el entrenamiento (Training Set), el modelo puede ahora evaluar nuevos datos y ofrecer predicciones o decisiones basadas en el aprendizaje previo.⁶ Por ejemplo, después de ser entrenado con datos sobre precios de viviendas, un modelo podría predecir el precio de una casa no listada basándose en sus características, como ubicación y tamaño. Esta capacidad de **generalizar** a partir de los datos aprendidos y aplicar ese conocimiento a situaciones no vistas anteriormente es lo que hace tan poderoso al aprendizaje automático.


⁶ **Atención:** no aprende de esos nuevos datos, para ello debería ser re entrenado.

UNIDAD 2. Material de estudio


2.6 Tipos de aprendizaje automático



El aprendizaje automático se suele dividir en dos tipos principales. En el enfoque **predictivo o supervisado**, el objetivo es aprender a relacionar entradas con salidas a partir de un conjunto de ejemplos etiquetados, es decir, se cuenta con datos donde cada entrada tiene asociada su correspondiente salida. En el caso más sencillo, cada entrada podría ser un conjunto de números que representan, por ejemplo, la etnia y el peso de una persona; estos números se conocen como características, atributos o covariables. Sin embargo, la entrada puede ser un objeto más complejo, como una imagen, una oración, un mensaje de correo, una serie temporal, la forma de una molécula, o incluso un grafo. Por supuesto, son transformados en números para ser interpretados por los computadores.


UNIDAD 2. Material de estudio

El segundo tipo principal de aprendizaje automático es el **enfoque descriptivo o no supervisado**. En este caso, únicamente se dispone de entradas y el objetivo es descubrir patrones interesantes en los datos, lo que se conoce a veces como descubrimiento de conocimiento. Esta tarea es menos precisa, ya que no se especifica de antemano qué patrones se deben buscar y no existe una métrica de error evidente para evaluar los resultados, a diferencia del aprendizaje supervisado donde se puede comparar la predicción con el valor observado.



UNIDAD 2. Material de estudio

Existe además un tercer tipo, **el aprendizaje por refuerzo**, que se utiliza para aprender a actuar o comportarse en función de señales de recompensa o castigo que se reciben de forma esporádica. Por ejemplo, se puede comparar este proceso con la forma en que un bebé aprende a caminar.



2.6.1 Aprendizaje Supervisado. Clasificación y Regresión


En este enfoque, el objetivo es aprender a relacionar unas entradas con unas salidas a partir de ejemplos previamente etiquetados. El tipo de variable que intentamos predecir determina el tipo de algoritmo que necesitamos.

Clasificación

En el contexto de la clasificación, la tarea consiste en asignar a cada entrada una etiqueta que representa una **clase o categoría**. Por ejemplo, si existen dos clases posibles, se denomina clasificación binaria; si hay más de dos, se conoce como clasificación multiclase. En ocasiones, una misma entrada puede pertenecer a varias clases a la vez (por ejemplo, una persona puede ser clasificada tanto como "alta" como "fuerte"), lo que se conoce como

UNIDAD 2. Material de estudio

clasificación con múltiples etiquetas. Sin embargo, al referirse generalmente a “clasificación”, nos referimos a la asignación de una única etiqueta por entrada.




Imagina que tienes una caja llena de frutas, pero en realidad sólo contiene frutillas y manzanas. Cada vez que tomas una fruta, alguien te dice si es una frutilla o una manzana. Con el tiempo, comienzas a notar características distintivas: las frutillas suelen ser más pequeñas, de color rojo brillante y con una forma particular, mientras que las manzanas son generalmente más grandes, redondas y pueden ser de varios colores.

En el aprendizaje supervisado, el proceso es muy similar. Se le muestra al modelo un conjunto de ejemplos (imágenes, en este caso) donde cada fruta **ya viene etiquetada** como "frutilla" o "manzana". El modelo aprende a relacionar las características visibles (como tamaño, forma y color) con la etiqueta correspondiente. El verdadero reto es lograr que, cuando el modelo vea una nueva imagen de una fruta que nunca había visto, pueda identificar correctamente si es una frutilla o una manzana basándose en lo que ha aprendido. Es decir, el objetivo es que el modelo generalice, funcionando bien no solo con los ejemplos de entrenamiento, sino también con nuevos datos.

Un modelo que aprende sobre el tamaño y la cantidad de azúcar que poseen las manzanas y las frutillas de un conjunto de datos observados puede ser un clasificador lineal, como en el ejemplo pedagógico siguiente. Frente a nuevos datos recopilados de una fruta podrá distinguir entre una manzana o una frutilla según el lado del semiplano donde se represente el punto, en relación con los valores que toman sus variables o coordenadas (Azúcar; Tamaño).

UNIDAD 2. Material de estudio

7




Regresión

La regresión es similar a la clasificación, pero la diferencia principal es que en la regresión la variable que queremos predecir o estimar es continua, en lugar de ser categórica o discreta.

Por ejemplo, imaginemos que estamos tratando de predecir la temperatura de un día específico basándonos en factores como la hora del día, la ubicación geográfica o la humedad. La temperatura es un número continuo que puede tomar cualquier valor dentro de un rango, como 25.3°C o 30.7°C.

⁷ Ejercicio pedagógico. Las posiciones referidas a las magnitudes podrían no ser exactas

UNIDAD 2. Material de estudio



En un caso simple de regresión, podríamos tener un solo dato de entrada, como la hora del día, y un único resultado, como la temperatura en ese momento. Para hacer esto, podríamos ajustar modelos matemáticos a los datos, como una línea recta o una curva cuadrática.

Existen muchas variaciones de este problema básico que pueden hacer que sea más complicado. Por ejemplo:

Geoffrey Hinton, un reconocido experto en aprendizaje automático, explicó que el cerebro humano procesa información de manera mucho más eficiente que si dependiera únicamente de ejemplos etiquetados. Si alguien le explicara a un niño qué es cada objeto una vez por segundo durante toda su vida, esa información sería insuficiente para comprender completamente el mundo. En cambio, la mayor parte del aprendizaje ocurre de manera no supervisada, al observar y analizar el entorno

2.6.2 Aprendizaje no-supervisado. Clusterin, anomalías, etc.


El aprendizaje no supervisado es un tipo de aprendizaje automático que trabaja con datos que no están etiquetados. Esto significa que el modelo recibe información sobre diferentes características o variables, pero no tiene acceso a una respuesta o etiqueta correcta que le sirva de guía. Por ejemplo, imagina que tienes un conjunto de datos sobre casas con información como el tamaño del terreno y la cantidad de habitaciones, pero sin un dato esencial: el precio de cada casa. Sin esa información, no puedes predecir cuánto vale cada casa usando ese modelo. Es decir, simplemente se nos da un conjunto de datos sin instrucciones claras sobre qué buscar o predecir. El objetivo principal es descubrir patrones o estructuras interesantes dentro de esos datos; a este proceso a veces se le llama "descubrimiento de conocimiento".

UNIDAD 2. Material de estudio

Entonces, ¿qué puede hacer el aprendizaje no supervisado? En lugar de intentar predecir algo específico, se enfoca en descubrir patrones o estructuras en los datos, entender la estructura interna. Permite descubrir información nueva o inesperada lo cual sería imposible si solo se buscara lo que ya se conoce.

Por ejemplo, se puede usar para identificar grupos similares dentro de un gran número de imágenes o para encontrar temas principales en un conjunto extenso de documentos.

Aprendizaje No Supervisado



En la vida real, el aprendizaje no supervisado se parece más al aprendizaje humano o animal. Por ejemplo, cuando un bebé está aprendiendo a ver, nadie le da instrucciones detalladas sobre qué es cada cosa; simplemente observa y va descubriendo patrones por sí mismo. De vez en cuando, alguien le dirá el nombre de un objeto, pero la mayor parte del aprendizaje ocurre solo mirando y explorando.

Imaginemos que tienes acceso a datos GPS de miles de viajes en taxi por Buenos Aires, con información sobre la duración de cada viaje y las direcciones de origen y destino. Sin embargo, no sabes cuáles son los puntos más populares para recoger o dejar pasajeros. Aquí es donde el aprendizaje no supervisado resulta útil. Puedes analizar esos datos y descubrir patrones. Por ejemplo:

Agrupar viajes similares: Identificar áreas donde muchos viajes comienzan o terminan, lo que podría indicarme dónde están las zonas más populares para recoger o dejar pasajeros.

UNIDAD 2. Material de estudio

Detectar rutas frecuentes: Encontrar caminos o trayectos que se usan mucho, lo cual puede revelar las principales calles o avenidas de la ciudad sin que nadie te lo haya dicho explícitamente.

El aprendizaje no supervisado funciona como un explorador curioso que organiza la información según cómo se relacionan sus partes. Además, es útil como paso previo al aprendizaje supervisado. Antes de crear un modelo que haga predicciones, puedes usar métodos no supervisados para ordenar y etiquetar mejor tus datos, facilitando el trabajo posterior.

2.6.2.1 Un ejemplo simple para entender cómo funciona.

El aprendizaje no supervisado se hace un poco más abstracto al no poseer etiquetas. Entonces veamos un ejemplo simple e intuitivo para entender su funcionamiento.



Supongamos que tenemos un curso con una cantidad de alumnos y alumnas. Y sabemos los nombres y las alturas de todos ellos. Nuestro objetivo es separar en dos grupos que representen a bajos y altos. Para ellos usaremos un modelo de aprendizaje no supervisado. Dos tipos de relaciones definen a los grupos y a los elementos en los grupos. Una intra grupo que es que dentro del mismo grupo los elementos tienen a ser similares en eso que

UNIDAD 2. Material de estudio

define el grupo. Y otra entre grupos que hace que un grupo se diferencia de otros grupos. O sea, similares **dentro** de cada grupo y distantes **entre** los grupos que se forman.⁸

Supongamos entonces que dividimos aleatoriamente los individuos en 2 grupos del mismo tamaño o lo más aproximado en caso de ser impares. Luego, para cada grupo calculamos la media de su altura como vemos a continuación.

Ahora aparece la idea. Para cada grupo se toma cada elemento y se compara con ambas medias. Luego, según esa medida esté más cerca de alguna de las dos defino una nueva columna debajo de las medias medidas y se coloca el individuo en la que tiene un valor de media más cercano. Generando así una nuevas 2 columnas en relación a esta aproximación.



Nombre	Altura		Nombre	Altura
Luis	1.78		Sergio	1.77
Julia	1.56		Eleonor	1.57
Maria	1.63		Carina	1.65
Pedro	1.85		Matias	1.64
Alvaro	1.71		Nicolás	1.59
Gonzalo	1.9		Santiago	1.73
Teresa	1.7		Beatriz	1.7
Paula	1.55		Miriam	1.62
Sandra	1.8		Jorge	1.85
Mabel	1.67		Yael	1.69
Oscar	1.76		Pablo	1.77
media	1.719090909		media	1.689090909
Nombre	Altura		Nombre	Altura
Luis	1.78		Julia	1.56


Si la distancia es la misma podemos incluirlas en cada grupo y una vez finalizado el procedimiento volveremos a calcular sus medias y repetiremos hasta que ya no haya más cambios de lado. Cuando esto ocurra habremos terminado de generar dos grupos en donde se diferenciarán las personas más bajas de las más altas de forma automática. Esta

⁸ En este caso hablamos de similitud y distancia matemática. Qué tan cerca o lejos se encuentran sus medidas de altura que es la característica que diferenciará los grupos.

UNIDAD 2. Material de estudio

metodología de reordenamiento es el centro del aprendizaje no supervisado. En un caso simple como este parece innecesario, pero es muy efectivo cuando la cantidad de variables (características) observadas para cada individuo es mayor. En esa complejidad, que deja de ser intuitiva muy rápidamente a medida que crece el número de variables, los algoritmos de aprendizaje no supervisado realizan mediciones para determinar qué individuos se parecen a cuales forman los grupos y en cómo se diferencian esos grupos entre ellos.

2.6.3 Aprendizaje por refuerzo.



El aprendizaje por refuerzo es un tipo de aprendizaje automático que se utiliza en áreas tan diversas como la robótica, los videojuegos y la navegación autónoma. A diferencia del aprendizaje supervisado o no supervisado, en este enfoque el modelo aprende interactuando con un entorno y tomando decisiones que le generan recompensas o castigos según su desempeño. Su objetivo principal es aprender a realizar acciones que maximicen la recompensa total acumulada a lo largo del tiempo.

Imaginemos un auto autónomo que necesita aprender a desplazarse desde un punto A hasta un punto B dentro de una ciudad. Aunque tiene acceso a un mapa y una señal de GPS, no sabe cuál es la mejor forma de llegar a su destino. En lugar de recibir instrucciones

UNIDAD 2. Material de estudio

precisas o ejemplos de rutas correctas, el auto aprende a través de ensayo y error. Al principio, sus movimientos son completamente aleatorios: gira en direcciones al azar, toma caminos equivocados o se detiene sin motivo aparente.

Cada acción que realiza se evalúa mediante un sistema de recompensas y castigos. Si toma un camino eficiente y llega más rápido a su destino, recibe una recompensa positiva. Por el contrario, si se desvía innecesariamente, toma una ruta más larga o infringe reglas de tránsito, recibe un castigo en forma de puntuación negativa. Al acumular experiencias y resultados, el auto empieza a identificar patrones que lo acercan a su objetivo de manera más eficiente. Aprende a evitar rutas poco prácticas, a respetar las normas y a optimizar sus trayectos con cada intento.

Este proceso de aprendizaje se diferencia claramente del aprendizaje supervisado, donde se proporcionan ejemplos con respuestas correctas para que el modelo aprenda de ellas, o del aprendizaje no supervisado, que busca descubrir patrones ocultos en datos sin etiquetas. En el aprendizaje por refuerzo, el modelo no recibe respuestas predeterminadas ni patrones que descubrir; en su lugar, aprende a mejorar continuamente mediante la retroalimentación que recibe después de cada acción.

Sin embargo, esta metodología tiene su costo. Al requerir tantas pruebas y errores para perfeccionar su desempeño, el aprendizaje por refuerzo consume mucho más tiempo y poder de cómputo que otros métodos. Cada intento fallido es parte del proceso de aprendizaje, pero también implica un uso intensivo de recursos.

En esencia, el aprendizaje por refuerzo se asemeja al entrenamiento de un animal: se premian los comportamientos deseados y se castigan los indeseados, hasta que, con suficiente práctica, el modelo aprende a actuar de manera correcta de manera autónoma.

2.7 Diseño de modelos.

El diseño de un modelo de aprendizaje automático no es un proceso en el que todas las técnicas sean intercambiables. Cada enfoque está diseñado para resolver un tipo específico de problema utilizando un conjunto particular de datos, y sus aplicaciones tienden a no superponerse. La clave para un proyecto exitoso es identificar qué técnica se adapta mejor al problema que deseas resolver.



Universidad
Nacional
de Rosario

Facultad de
Ciencias Exactas,
Ingeniería y Agrimensura



Introducción a la
Inteligencia Artificial

UNIDAD 2. Material de estudio

El aprendizaje supervisado es la opción ideal cuando se dispone de un gran volumen de datos etiquetados, es decir, aquellos en los que se conocen tanto las variables explicativas como la variable objetivo. Por ejemplo, si estás desarrollando un filtro de correos electrónicos no deseados (spam), podrías tener un conjunto de datos con correos ya clasificados como “spam” o “no spam” (variable objetivo) y otros detalles como el nombre del remitente y el asunto del correo (variables explicativas). En este caso, el aprendizaje supervisado funciona perfectamente porque se trata de aprender a predecir una etiqueta conocida a partir de datos previamente etiquetados.

Por otro lado, el aprendizaje no supervisado se utiliza cuando se tiene una gran cantidad de datos de entrada pero sin etiquetas que indiquen lo que se espera obtener. Su propósito principal es descubrir patrones ocultos, agrupaciones o estructuras dentro de esos datos. Imaginemos que trabajas en un proyecto de análisis de marketing donde deseas segmentar clientes según sus comportamientos o preferencias de compra. Con métodos no supervisados como el clustering, puedes identificar grupos de clientes con características similares sin necesidad de tener categorías predefinidas. Este tipo de problema no puede ser abordado adecuadamente con aprendizaje supervisado, ya que no existen etiquetas previas que orienten al modelo.

El aprendizaje por refuerzo, por su parte, es adecuado para situaciones en las que el modelo debe aprender a tomar decisiones interactuando con un entorno que presenta una serie de acciones secuenciales. Este tipo de aprendizaje se destaca en escenarios como el desarrollo de sistemas que juegan ajedrez o videojuegos, donde la IA aprende estrategias óptimas mediante prueba y error. Durante cada partida, recibe recompensas o penalizaciones dependiendo de la calidad de sus decisiones. Sin embargo, este enfoque no sería adecuado para tareas como predecir precios de viviendas o clasificar correos electrónicos, ya que no implican un proceso de toma de decisiones secuencial dentro de un entorno definido.


2.7.1 Los datos. Entrenamiento de un modelo.

Supongamos que tenemos dos **variables (a, b)** medidas para una serie de individuos. Cada uno estará representado en un punto que corresponde a las coordenadas para ese individuo. *Figura siguiente.*

Entonces hemos representado nuestras observaciones (individuos) en estas dos dimensiones conformando una nube de puntos. Nuestro objetivo es pensar un modelo que

UNIDAD 2. Material de estudio


nos permita poder hacer un pronóstico de b dado un valor de a . En el ejemplo del apartado 2, pronosticar la altura en centímetros de un individuo dado su peso en kilogramos.



$$b = m a + h$$

En los puntos graficados observamos un posible *correlación* entre los valores de a y los valores de b . Observamos que para valores de a más grandes, “en promedio” se observan valores más grandes de b . Podemos suponer que la forma funcional (el modelo) lineal, es una buena idea para representar esa relación entre las variables. Así que intentamos “ajustar” una recta que represente, lo mejor posible, esa relación subyacente.


UNIDAD 2. Material de estudio



$$b = m a + h$$


2.7.2 ¿Cómo definimos que este es el modelo lineal que mejor se ajusta a este fenómeno?.

Nuestro modelo ideal tendrá un determinado valor para h y uno para m . Al variar estos valores se altera la posición de nuestros modelos. Si variamos la ordenada al origen, o sea " h " veremos un corrimiento en forma paralela de la recta en la gráfica.



UNIDAD 2. Material de estudio

En este caso disminuyendo el valor de “h” vemos un corrimiento de la recta hacia abajo. En cambio si lo que cambia es el valor de “m”, la pendiente veremos cómo la inclinación del modelo lineal varía:




En este caso al aumentar el valor de “m” la recta gira en sentido antihorario, es decir se hace más vertical.

Pero entonces. ¿Cómo definimos cuál es el par de “h” y “m” que **mejor** representa la relación entre las variables? Para esto, nos basamos en una **métrica de error** que representa la suma de las distancias verticales al cuadrado⁹ desde los valores de “b” del modelo (sobre la recta amarilla), con respecto a los valores “b” de los puntos para el mismo valor de “a” en ambos casos. Hay que entender que el valor de “b” correspondiente al punto sobre la recta para un nivel de “a” es el valor “predicho” de “b” que nos proporciona el modelo para ese valor de “a”. Al valor de “b” del punto lo llamamos “valor observado”.

Entonces, el modelo será el adecuado cuando los valores de “h” y “m” se correspondan con la recta que pasa a **menor distancia total** para cada punto (mínimo error entre observado y predicho).

⁹ La forma cuadrática se utiliza porque las diferencias entre los observados y los pronósticos del modelo pueden dar valores positivos y negativos que pueden anularse unos a otros. Como nos interesa el total del error la forma cuadrática, que genera solo valores positivos, es una métrica muy utilizada para evaluar el error.

UNIDAD 2. Material de estudio



Así si pudiéramos comparar todos los valores de “error” decidimos que par de “m” y “h” se corresponden con el modelo lineal que tiene **menor error entre la predicción del modelo a los puntos observados**.

Importante: los valores de las variables **a** y **b** en los vectores ya están determinados numéricamente y corresponden, en el ejemplo, al peso y la altura que observamos (datos de entrada, los puntos en la gráfica) para los individuos.¹⁰ En cambio, **m** y **h** aún no están valorados, este es el objetivo del aprendizaje.

Veamos el proceso de forma de ecuación:

¹⁰ Notar que los subíndices en los vectores indican la observación, por ejemplo si el total de individuos a los que se les mide altura y peso son 5. $n = 5$, $n-1 = 4$, etc.

UNIDAD 2. Material de estudio

$$\begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_{n-1} \\ b_n \end{bmatrix} = m \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_{n-1} \\ a_n \end{bmatrix} + h$$

Como vemos, antes del entrenamiento, los puntos observados están representados por los vectores **a** y **b**. En el **entrenamiento** se busca **estimar** (que el modelo aprenda) los valores de los parámetros **h** y **m**, que **minimicen** el **error** entre todos los puntos observados y el modelo lineal (línea amarilla).

El siguiente es una posible ecuación resultante (**MODELO ENTRENADO**) :

$$\hat{b} = 130 + 0.5a$$

donde **h** estimado toma el valor **130** y **m** estimado toma el valor **0.5**

Ahora, para utilizar el modelo entrenado para **PREDECIR** el valor de *b sombrero*¹¹ (pronóstico de altura) debemos ingresar un valor de **a** (peso) y resolver. Por ejemplo, si el peso de un nuevo individuo es 65 kg:

$$\hat{b} = 130 + 0.5 \times 65$$

$$\hat{b} = 130 + 32,5$$

$$\hat{b} = 162,5$$

El pronóstico de altura para una persona que pesa 65 kg *en promedio* es de 162,5 cm

¹¹ Representa que el modelo ya ha sido entrenado. Y que al calcular la ecuación nos dará un valor de b predicho. Una predicción de cuál puede ser la altura para el valor de peso que ingresemos.

UNIDAD 2. Material de estudio

2.7.3 ¿Cómo se realiza el ajuste óptimo?


En nuestro ejemplo de ajuste estamos tratando de ajustar un modelo lineal. En regresión lineal existe un algoritmo llamado mínimos cuadrados que permite llegar a un valor de los parámetros óptimo que minimiza el error. El problema que tenemos con este algoritmo es que en el machine learning la cantidad de variables a utilizar pueden hacer que esta “solución cerrada”¹² necesite de un cálculo muy complejo. Por eso en general se utiliza un algoritmo iterativo que va aproximándose a un valor óptimo. Este algoritmo es conocido como *descenso de gradiente*.

Descenso de gradiente.

La estrategia de descenso de gradiente implica cambiar de “escenario”, si en las gráficas donde mapeamos las observaciones y el modelo era el universo de las variables (En los ejes estaban **a** y **b** las variables observadas). Cuando hablamos de descenso de gradiente los ejes van a representar los rangos de valores donde se mueven nuestros parámetros, **h** y **m**. Tomando los ejes donde cohabitan todos los valores posibles de los parámetros (ejes **h** y **m**) se puede observar una gráfica como la siguiente en relación al error (eje vertical):

¹² Solución cerrada: una fórmula que te da la respuesta exacta en un solo paso.

UNIDAD 2. Material de estudio




Nuestro objetivo es minimizar ese error que, como es evidente, corresponderá con el punto más bajo (el mínimo de la función aquí representada).

Para entender el algoritmo de *descenso de gradiente* imagina que estás en un valle con los ojos vendados (algún punto en la parte alta de la curva azul). Tocas el suelo y sientes la inclinación del terreno. Eso te dice hacia dónde bajar. Das un pasito. Vuelves a tocar el suelo. Sientes otra inclinación, y das otro pasito. Así, vas bajando... hasta que el terreno se siente plano: ¡llegaste al mínimo! En este caso la parte más baja de la curva azul.

Pero, cuando la función es más compleja, podemos encontrar mínimos locales¹³ además de un mínimo general. En la figura siguiente vemos diferentes valles en una superficie más accidentada. Los puntos más bajos de esos valles (menos el más profundo) son los mínimos locales.

¹³ Un mínimo es la parte más profunda de un valle en esta curva. La derivada se hace 0 en máximos y mínimos de una función.

UNIDAD 2. Material de estudio



Para enfrentar esta dificultad existen estrategias que dan la posibilidad de cambiar el largo del “pasito” y/o el punto de inicio del descenso. Entonces, realizando iterativamente el mismo proceso, nos permite diferenciar los mínimos locales del mínimo general. Así, con ayuda de la potencia computacional, podemos evitar quedarnos atrapados en un mínimo local y *aproximarnos* al mínimo de la función. Imagina esto como alguien de grandes piernas puede salir de un pozo profundo, o no caer en él para seguir su camino.¹⁴ El punto al que llegamos será ,posiblemente, el mínimo de la función. Luego, buscamos los valores de las coordenadas en los ejes que representan los valores de parámetros que pondremos en nuestro modelo entrenado. En nuestro ejemplo los valores de **m** y **h** que estábamos buscando.

Importante: recordar que los ejes horizontales representan el rango de valores para los parámetros. Y el eje vertical el rango de valores del error.

¹⁴Un paso demasiado amplio también presenta sus complicaciones en la búsqueda de un mínimo, pero eso lo veremos más adelante en próximas materias.

UNIDAD 2. Material de estudio

2.8 Complejidad del modelo vs Generalización

Muchas veces puede ser que los fenómenos que tratamos de modelizar tengan componentes no lineales. Es así que en un modelo lineal al ingresar variables con un grado de exponente mayor puede significar tomar algún patrón no lineal que una relación proporcional entre los valores de las variables no representa. Este es el caso que se da cuando en una ecuación polinómica de grado 1 del tipo:

$$\hat{Y} = \beta_1 X + \beta_0$$

15

puede complejizarse introduciendo no linealidades en la variable explicativa, por ejemplo ingresando su valor al cuadrado.

$$\hat{Y} = \beta_2 X^2 + \beta_1 X + \beta_0$$


o al cubo.¹⁶

$$\hat{Y} = \beta_3 X^3 + \beta_2 X^2 + \beta_1 X + \beta_0$$

¹⁵ Notar que los Beta aquí representan los coeficientes o parámetros. X los datos observados e Y sombrero el predicho.

¹⁶ Cada grado superior de polinomio permite a la curva tener un punto más de inflexión. O sea, cambiar de dirección.

UNIDAD 2. Material de estudio




Obteniendo una reducción del error a medida que aumentamos el grado del polinomio.

2.8.1 Complejizar el modelo.

Pero entonces. ¿Por qué no seguir aumentando la complejidad hasta obtener toda la información que las observaciones nos brindan? Por ejemplo, haciendo el grado del polinomio tan grande como la cantidad de observaciones en el conjunto de datos recolectado:

UNIDAD 2. Material de estudio



El problema de esta estrategia es que aquí no solo estamos llevándonos información que los datos tienen sobre la *relación subyacente* sino que además, nos estamos llevando el “*Ruido*”. Porque lo que estamos suponiendo es que la relación ideal que estamos buscando entre estas dos características de los individuos tiene una forma general más suave (sin tanta variación). Como en la **gráfica XXX** o incluso en el modelo lineal. Y que las diferencias de los datos observados con el modelo son resultado de la complejidad del mundo que nuestro modelo no puede explicar.

2.8.2 Ruido y error.

Muchas veces se habla de *error* y de *ruido* y sin embargo a veces queda poco claro de qué estamos hablando cuando no diferenciamos estos conceptos.

Ruido: es “*todo lo que el modelo no explica*” entre la suposición de cual es la forma subyacente de la relación (modelo) y la realidad observada. Es parte de la complejidad de la realidad.

UNIDAD 2. Material de estudio

Cuando construimos un modelo, por ejemplo uno lineal para predecir la altura de una persona a partir de su peso, asumimos que existe una relación regular entre esas dos variables. Sin embargo, no todo lo que afecta la altura está incluido en nuestro modelo: factores como la genética, la edad, el sexo o incluso errores de medición pueden influir. A eso lo llamamos *ruido*. El ruido representa todas esas influencias que el modelo no puede captar ni explicar, y que provocan que los datos reales se dispersen alrededor de la línea de regresión. Es decir, el ruido es inherente a la realidad y por lo tanto viene en los datos y no depende del modelo en sí, sino de la complejidad del mundo que intentamos representar.

Importante: El ruido no es algo estático ni modelable.

En el contexto del aprendizaje automático, es importante entender que el *ruido* no es simplemente “un valor incorrecto” o “una desviación puntual”: es una manifestación de la complejidad del mundo real que el modelo no puede capturar. No es constante, ni tiene una única causa, ni se comporta de forma predecible. Puede variar de un caso a otro, surgir de múltiples fuentes (factores ocultos, errores de medición, condiciones externas, decisiones humanas, etc.), y lo más importante: **no es modelable en sí mismo**.

Error: *Es la diferencia entre el valor de la predicción al valor real (observado)*

Una vez que el modelo ha sido entrenado y se utiliza para hacer predicciones, podemos comparar cada valor observado (por ejemplo, la altura real de una persona) con el valor que el modelo predice para ese mismo caso. La diferencia entre ambos se llama *error*. Este error es específico de cada observación y depende tanto del ruido como de qué tan bien el modelo fue capaz de ajustar la relación entre peso y altura. Mientras el ruido es un concepto más general que se refiere a todo lo que está fuera del alcance del modelo, el error es una medida puntual, que nos dice cuánto se desvió el modelo en un caso concreto.

Metafóricamente podemos decir: “El error es la **sombra** del ruido una vez que extraemos el fenómeno de la muestra con el modelo”

UNIDAD 2. Material de estudio

Con los datos recolectados, al ajustar un modelo demasiado complejo estamos absorbiendo patrones que NO son propios de la *relación subyacente* que buscamos modelar. Sino, que provienen de todo lo que no es esa relación. Es información generada por el *ruido*. Metafóricamente podemos decir:

“Nos pasamos de rosca! Tomamos más información de la necesaria al intentar ajustar la relación que nos importa modelar. “

Esto es lo que se denomina **Overfitting** o **sobreajuste**

2.8.3 Datos de entrenamiento y de test. Evaluando el ajuste.


Como habíamos dicho en un apartado anterior, nuestro objetivo es ajustar el modelo que mejor representa la relación subyacente y con este hacer predicciones sobre datos nuevos. El problema es:

¿Cómo evalúo que no estoy llevando patrones que no corresponden al modelo?

Necesitamos, entonces, evaluar diferentes modelos con diferentes grados de complejidad para establecer cual el mejor grado de complejidad que posibilita extraer el fenómeno general o relación subyacente que estamos tratando de ajustar con nuestro modelo. La estrategia para hacer esto es empírica. Y parte del mismo lugar con el que se entrenan los modelos. Del total de los datos observados.

Supongamos, en nuestro ejemplo, que tenemos el peso y la altura de 30 *individuos*. Del total, destinamos una cantidad mayor a entrenar y reservamos una parte menor para evaluar. Una buena práctica puede ser 80% entrenamiento (24 observaciones) y 20% (6 observaciones) para test. En general los porcentajes de 80 y 20 son una buena práctica, pero no es necesario que sean estrictamente esos valores.

UNIDAD 2. Material de estudio




Esto tiene sentido. ¿Por qué?

Para evaluar la bondad de ajuste de un modelo, necesitamos contar con valores observados de la variable respuesta que nos permitan comparar los pronósticos generados. En este caso, necesitamos conocer la altura real (observada) asociada al peso de cada individuo, para contrastar con la altura predicha por el modelo.

Una vez que entrenamos el modelo con el 80% de los datos, lo aplicamos sobre el 20% restante, que reservamos como conjunto de prueba. Es decir, usamos los valores de peso de ese 20% para generar predicciones de altura, y luego comparamos esas predicciones con los valores reales. De esta forma, podemos estimar qué tan precisas son las predicciones del modelo y, a partir de esa distancia entre lo predicho y lo observado, evaluar qué grado de complejidad es más adecuado para un buen desempeño fuera del entrenamiento.

En la figura siguiente se muestra una gráfica que representa cómo varía el desempeño (eje Y) de distintos modelos en función de su complejidad (eje X), es decir, cómo cambia el error de predicción. La curva verde refleja el desempeño sobre los datos de entrenamiento. A medida que la complejidad del modelo aumenta. Por otro lado, la curva naranja representa el desempeño sobre los datos de prueba (test) en relación con la complejidad del modelo.

UNIDAD 2. Material de estudio



Analicemos ahora los momentos destacados en la gráfica, marcados con elipses:

En el primer tramo (a la izquierda), observamos un desempeño bajo. Ambas curvas —entrenamiento y test— se mueven de manera similar, aunque claramente el desempeño mejora a medida que se incrementa la complejidad del modelo. Este es el escenario de subajuste (**underfitting**): el modelo aún no ha captado adecuadamente la estructura del fenómeno y tiene margen para mejorar. En este punto, aumentar la complejidad puede permitir que el modelo extraiga más información útil de los datos y se aproxime mejor a la relación subyacente.

A medida que avanzamos hacia la derecha, el desempeño de ambas curvas continúa mejorando hasta alcanzar una zona de estabilización. Ese momento, conocido como **sweet spot**, marca el equilibrio óptimo entre complejidad y capacidad predictiva. Representa el punto en el que el modelo ha capturado de manera eficiente el patrón presente en los datos sin sobreajustarse. Este es, en general, el grado de complejidad que buscamos al entrenar un modelo.

Finalmente, en el tramo derecho de la gráfica nos encontramos con el fenómeno de sobreajuste (**overfitting**). Aquí, la curva de entrenamiento sigue mejorando, pero ya no refleja una verdadera comprensión del fenómeno, sino una adaptación excesiva a las particularidades del conjunto de entrenamiento —incluido su ruido—. Como resultado, al



Universidad
Nacional
de Rosario

Facultad de
Ciencias Exactas,
Ingeniería y Agrimensura



**Introducción a la
Inteligencia Artificial**

UNIDAD 2. Material de estudio

aplicar el modelo a los datos de prueba, el desempeño empeora: las predicciones se alejan de los valores observados, lo que indica que la capacidad de generalización se ha deteriorado.