

Unidad 5 - Visión por Computadora

# Diplomatura en Inteligencia Artificial

## TUIA - 2025

Prof: Lic Alan Geary - email: [alan.geary.b@gmail.com](mailto:alan.geary.b@gmail.com) 

# Visión por computadora

La visión por computadora estudia la **percepción visual**: es la ciencia de percibir y entender el mundo a través de las imágenes y videos construyendo modelos físicos del mundo para que un **sistema de IA** pueda tomar las acciones apropiadas

Elgandy, 2020

Los humanos podemos ver una imagen y en muy poco tiempo entenderla, prestar atención a lo importante y descartar lo irrelevante.

La habilidad de describir el contexto de una imagen como lo hacemos los humanos es una de los requisitos que debería tener una IA de nivel humano.

Mitchell, 2019

# Visión por computadora (CV)

Algunos conceptos:

- **Percepción visual:** Es el acto de observar patrones y objetos a través de la vista o una entrada visual
- **Sistemas de visión:** Hace unos años, el procesamiento de imágenes era considerado CV. Hoy, es solo una parte de un sistema más grande y complejo que intenta interpretar el contenido de las imágenes
- **Sistemas de visión de inteligencia artificial:** Inspirados en la visión humana. Necesitan dos componentes: un *sensor* y un *intérprete*. En el humano es el par ojo-cerebro, en la IA es la cámara-computadora

# Las cosas fáciles son difíciles

Primero, necesitamos reconocimiento de objetos, reconocer grupos de píxeles como objetos: mujer, perro, globo. El problema en reconocer objetos es que la computadora tiene que identificar píxeles de perros y de no-perros. Además, diferentes perros se ven diferentes, el animal posa de forma diferente, la luz entre las fotos varía, etc.

Y además, los píxeles de perros pueden parecerse a los de otro animal.



# SISTEMA VISUAL HUMANO

---

## Optic nerve

Information from the light-sensitive cells in the eyes is passed to the brain via the optic nerve

### Optic nerve

The optic nerve carries signals away from the eye and toward the brain.

## Thalamus

The thalamus is situated deep inside the brain, involved in relaying sensory information, including vision, hearing and touch.

## Visual cortex

The visual cortex made up of six separate parts, located right at the back of the brain.

### Focusing

The lens changes shape depending on the distance to the object, focusing the light onto the retina.

### Object

As light hits an object, it is reflected, bouncing away from its surface in all directions.

### Lens

As light passes through the lens, its path is bent, focusing the waves in toward the retina.

### Optic tract

The optic nerve extends toward a region of the thalamus known as the lateral geniculate nucleus (LGN).

### Optic chiasm


The optic nerves from each eye cross over as they enter the brain. The signals from the left side of each eye go to the left side of the brain, and vice versa.

### Lateral geniculate nucleus (LGN)

There are LGNs, one on the left, and one on the right. They act as relays and send the information on to the visual cortex.


### Primary visual cortex

Arranged like a map of the retina, it has a large area dedicated to the fovea - the region of the eye responsible for detailed colour vision.




# ESPECTRO VISIBLE

---



# Ejemplos de equipos de Visión por computadora



# HISTORIA



**David Hubel y Torsten Wiesel** ganaron el premio Nobel (1981) por descubrir la organización jerárquica en los sistemas visuales de gatos primates y por la explicación sobre cómo el sistema visual toma la luz que llega a la retina y la transforma en información de la escena.



# HISTORIA




**Kunihiro Fukushima** se inspiró en la idea de Hubel y Wiesel y generó unas de las primeras **redes neuronales** que podían reconocer dígitos escritos a mano.

- La idea de Fukushima inspira desarrollos futuros como las **ConvNets**

# HISTORIA

ConvNets fueron propuestas en 1980 por **Yann LeCun**

*Las CNN al basarse en el funcionamiento de la corteza visual, también*




*las imágenes para después poder clasificarlas. Dentro de esta capa se tienen*




# PIPELINE DE ALGORITMO DE VC

Las aplicaciones de CV varían pero todas usan una serie de pasos para procesar y analizar imágenes.




# PIPELINE DE ALGORITMO DE VC



# PIPELINE DE ALGORITMO DE VC

1. Una computadora recibe un input visual, imagen o video
2. La imagen se preprocesa para estandarizarla: cambio de tamaño, blurring, rotación, cambio de color, etc.
3. Extracción de características que ayudan a identificar un objeto. En el ejemplo de la moto podrían ser el manubrio, las ruedas, etc. El resultado es el vector de características.
4. Se usa un modelo de clasificación para predecir qué objeto es (con cierta probabilidad) usando el vector de características.




# IMÁGENES COMO FUNCIONES

---

# Datos de entrada - Imágenes como funciones

Las imágenes se pueden representar como una **función de dos variables**,  $x$  e  $y$ .

Una imagen digital es un grupo de píxeles donde el valor de píxel representa la intensidad de la luz. en escala de grises, *255 para el blanco y 0 para el negro*



**Figure 1.15** Images consists of raw building blocks called *pixels*. The pixel values represent the *intensity* of light that appears in a given place in the image.

# Datos de entrada - La imagen en los “ojos” de la computadora

What we see




What computers see

|    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |
|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|
| 08 | 02 | 22 | 97 | 38 | 15 | 00 | 40 | 00 | 75 | 04 | 05 | 07 | 78 | 52 | 12 | 50 | 77 | 91 | 08 |
| 49 | 49 | 99 | 40 | 17 | 81 | 18 | 57 | 60 | 87 | 17 | 40 | 98 | 43 | 69 | 46 | 04 | 56 | 62 | 00 |
| 81 | 49 | 31 | 73 | 55 | 79 | 14 | 29 | 93 | 71 | 40 | 67 | 53 | 99 | 30 | 03 | 49 | 13 | 36 | 65 |
| 52 | 90 | 95 | 23 | 04 | 60 | 11 | 42 | 69 | 24 | 48 | 56 | 01 | 32 | 54 | 71 | 37 | 02 | 34 | 91 |
| 22 | 31 | 14 | 71 | 51 | 67 | 43 | 59 | 41 | 92 | 34 | 54 | 22 | 40 | 40 | 28 | 44 | 33 | 13 | 80 |
| 24 | 47 | 32 | 60 | 99 | 03 | 45 | 02 | 44 | 75 | 33 | 53 | 78 | 36 | 64 | 20 | 35 | 09 | 12 | 80 |
| 32 | 98 | 81 | 28 | 64 | 23 | 67 | 10 | 26 | 38 | 40 | 67 | 59 | 54 | 70 | 66 | 18 | 38 | 64 | 70 |
| 47 | 24 | 20 | 68 | 02 | 62 | 12 | 20 | 95 | 63 | 94 | 39 | 63 | 04 | 49 | 91 | 44 | 49 | 94 | 21 |
| 24 | 55 | 58 | 05 | 66 | 73 | 99 | 26 | 97 | 17 | 78 | 78 | 94 | 83 | 14 | 88 | 34 | 89 | 63 | 72 |
| 21 | 36 | 23 | 09 | 75 | 00 | 74 | 44 | 20 | 45 | 35 | 14 | 00 | 41 | 33 | 97 | 34 | 31 | 33 | 95 |
| 78 | 17 | 53 | 28 | 22 | 75 | 31 | 67 | 15 | 94 | 03 | 80 | 04 | 42 | 16 | 14 | 09 | 53 | 56 | 92 |
| 16 | 39 | 05 | 42 | 96 | 35 | 31 | 47 | 55 | 58 | 88 | 24 | 00 | 17 | 54 | 24 | 34 | 29 | 85 | 57 |
| 84 | 56 | 00 | 48 | 35 | 71 | 89 | 07 | 05 | 44 | 44 | 37 | 44 | 40 | 21 | 58 | 51 | 54 | 17 | 58 |
| 19 | 80 | 61 | 68 | 05 | 94 | 47 | 49 | 28 | 73 | 92 | 13 | 86 | 52 | 17 | 77 | 04 | 09 | 55 | 40 |
| 04 | 52 | 08 | 83 | 97 | 35 | 99 | 14 | 07 | 97 | 57 | 32 | 16 | 26 | 26 | 79 | 33 | 27 | 98 | 44 |
| 04 | 36 | 68 | 81 | 57 | 62 | 20 | 72 | 03 | 16 | 33 | 67 | 46 | 55 | 12 | 32 | 43 | 93 | 53 | 69 |
| 04 | 42 | 14 | 73 | 38 | 25 | 39 | 11 | 24 | 94 | 72 | 18 | 06 | 46 | 29 | 32 | 40 | 62 | 74 | 36 |
| 20 | 49 | 34 | 41 | 72 | 30 | 23 | 88 | 34 | 62 | 99 | 69 | 82 | 47 | 59 | 85 | 74 | 04 | 34 | 24 |
| 20 | 23 | 35 | 29 | 78 | 31 | 90 | 01 | 74 | 31 | 49 | 71 | 48 | 86 | 81 | 14 | 23 | 57 | 05 | 54 |
| 01 | 70 | 54 | 71 | 83 | 51 | 54 | 49 | 16 | 92 | 33 | 48 | 61 | 43 | 51 | 01 | 89 | 19 | 67 | 48 |




# Datos de entrada - La imagen en los “ojos” de la computadora

La computadora ahora ve la imagen a través de los 3 canales de RGB, 3 matrices en lugar de 1.




# PROCESAMIENTO

- Estandarizar el tamaño de las imágenes de entrada para que todas tengan el mismo tamaño.
- Convertir las imágenes a la escala de grises para reducir la complejidad.
- Aumento de datos. Incrementar el dataset con versiones modificadas de la imagen original: rotaciones, aumento de tamaño, etc.



# Extracción de features

Se extraen las features para reducir la complejidad de la información de entrada (la imagen) y solo quedarnos con la información que es realmente esencial para clasificar a la imagen




# Extracción de features (características)

En **ML** las features son características mensurables de un fenómeno. Son lo que llamamos las *variables independientes* que nos ayudan a predecir a la variable dependiente.

En CV, una feature es una porción de datos de la imagen que es única para ese objeto, por ejemplo, un color o una forma particular.


Por ejemplo, si nos dicen que la feature es una rueda y nos piden decidir si la imagen es una moto o un perro, la feature es buena para la predicción.




# Extracción de features

En **ML tradicional** se dedica una porción considerable de tiempo en elegir las features. Se confía en expertos en el tema.

Luego se usan esas features como inputs de un modelo de ML como ser un support vector machine.




# ¿Cómo seleccionar una característica?



¿ Qué hace que la característica Altura (height) sea útil ?

# ¿Cómo seleccionar una característica?




¿ Qué hace que la característica color de ojos no sea útil ?

# Extracción de features

En **DL**, la red *extrae los features automáticamente* y aprende su importancia en el resultado final aplicando pesos a las conexiones.

Las redes neuronales pueden ser pensadas como extractores de features + clasificadores que son entrenables de fin a fin.






# Extracción de features


Tenemos una CNN con 4 capas y un módulo de clasificación para reconocer razas de perros.

Los datos de entrada son imágenes en escala de grises


El resultado final es una distribución de probabilidades de que sea una raza u otra.



# Detección de bordes




# Detección de bordes - Convolución



$$200*1+110*0+\dots = 410$$

Como se ve en el mapa de activación, el pixel central de la unidad de análisis se colorea de blanco para resultados positivos y de negro para resultados cercanos a 0



Input

kernel/filtro

Feature Map(Mapa de características)

# Pooling

La segunda técnica importante sobre CNN (después de convolución) es la agrupación (pooling)

Max Pooling

|   |   |   |   |
|---|---|---|---|
| 2 | 7 | 9 | 7 |
| 4 | 9 | 1 | 4 |
| 4 | 7 | 6 | 2 |
| 5 | 1 | 8 | 2 |

|  |  |
|--|--|
|  |  |
|  |  |

Average Pooling

|   |   |   |   |
|---|---|---|---|
| 2 | 7 | 9 | 7 |
| 4 | 9 | 1 | 4 |
| 4 | 7 | 6 | 2 |
| 5 | 1 | 8 | 2 |




|  |  |
|--|--|
|  |  |
|  |  |

# Jerarquía

Los mapas son jerárquicos, es decir, los inputs de la capa 2 son los outputs de la capa 1.

Cada vez que pasamos a una layer superior vamos complejizando el aprendizaje

Mitchell, 2019



# Clasificación

Una vez que la red detecta los features necesarios, se genera el **feature vector** que se utiliza para alimentar una red neuronal tradicional y se procede a la clasificación.

La clasificación devuelve una distribución de probabilidades de que el objeto sea cada uno de los objetos conocidos por la red

